Workflow proyecto machine learning

Regresión lineal

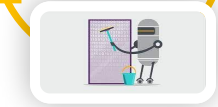
LinearRegression

Interpretar el Modelos en Machine Learning es la habilidad de explicar su funcionamiento ó presentarlo de manera comprensible al humano.

1 RECOLECTAR DATOS



2 PREPARAR LOS DATOS



3 ELEGIR EL MODELO



4 ENTRENAR MODELO



5 PREDICCIÓN O INFERENCIA



6 EVALUACIÓN DEL MODELO



7 INTERPRETACIÓN DEL MODELO



8 DESPLEGAR EL MODELO

pandas NumPy seaborn matplotlib

statsmodels scikit learn seaborn matplotlib

Streamlit

Preprocesamiento de datos

Esta Fase ocupa el 70-80%del tiempo de desarrollo.

Operaciones a realizar

1. Recolección de datos
2. Limpieza de Datos [data Cleaning]
3. Transformación deDatos
4. Reducción de datos
5. Integración de datos.
6. Discretización de datos.

¿De donde vienen los datos?

¿Qué es data mining

¿De dónde vienen todos los datos?

- Datos de usuarios y/o clientes de instituciones y empresas.
- Datos generados por transacciones (compras, transferencias, ...).
- Datos adquiridos por sensores (de temperatura, de humedad, ...).
- ***Datos subidos a redes sociales (textos, imágenes, vídeos, ...).***
- Datos relacionados con la salud (historiales y pruebas realizadas a pacientes).
- Datos de geolocalización (posicionamiento en cada momento según GPS).
- Datos guardados en logs (de todos los accesos que hacemos a páginas web).
- Datos producidos por el Internet de las cosas (de los diversos dispositivos IoT).
- Datos producidos por la genómica (cada vez que se secuencia un genoma).
- Datos de meteorología (información obtenida por satélites y las predicciones realizadas a partir de la misma).
- Datos producidos por cámaras (imágenes estáticas y vídeos producidos).
- Datos producidos por micrófonos (grabaciones de sonido producidas).
- Datos de RFID (aquellos con los que se tratan al realizar identificación por radiofrecuencia). Datos producidos por los sectores energético e industrial (toda la información que se genera alrededor de la energía y la industria).
- Datos Open Data (todos los datos abiertos liberados ya sea a nivel gubernamental o no gubernamental).

Preprocesamiento de datos

EDA. Exploratory Data Analysis

1.-Tener clara la pregunta que queremos responder.
2.-Tener una idea general de nuestro dataset.
3.-Definir los tipos de datos que tenemos.
4.-Elegir el tipo de estadística descriptiva.
5.-Visualizar los datos.
6.-Analizar las posibles interacciones entre las variables del dataset.
7.-Extraer algunas conclusiones de todo este análisis.

Nuestro preprocesamiento

1. **Importación de datos RAW**
2. **Elegir variables de interés**
   Elegimos las características para nuestro modelo
3. **Estudio estadístico: dispersión y centralización**
   Cálculos y visualización
4. **Detección NaN**
   Detección de valores nulos y su corrección
5. **Detección Outliers**
   Detección de valores anómalos y como proceder.
6. **Split de Datos**
   Separación de datos en train test y validation
7. **Escalado de Características**
   Normalización en casos de modelos no robustos.
8. **Análisis de correlación: detec. multicolinealidad**
   Análisi s de componentes principales para reducción de dimensiones.

¿De dónde vienen todos los datos?

- Datos de usuarios y/o clientes de instituciones y empresas.
- Datos generados por transacciones (compras, transferencias, ...).
- Datos adquiridos por sensores (de temperatura, de humedad, ...).
- ***Datos subidos a redes sociales (textos, imágenes, vídeos, ...).***
- Datos relacionados con la salud (historiales y pruebas realizadas a pacientes).
- Datos de geolocalización (posicionamiento en cada momento según GPS).
- Datos guardados en logs (de todos los accesos que hacemos a páginas web).
- Datos producidos por el Internet de las cosas (de los diversos dispositivos IoT).
- Datos producidos por la genómica (cada vez que se secuencia un genoma).
- Datos de meteorología (información obtenida por satélites y las predicciones realizadas a partir de la misma).
- Datos producidos por cámaras (imágenes estáticas y vídeos producidos).
- Datos producidos por micrófonos (grabaciones de sonido producidas).
- Datos de RFID (aquellos con los que se tratan al realizar identificación por radiofrecuencia). Datos producidos por los sectores energético e industrial (toda la información que se genera alrededor de la energía y la industria).
- Datos Open Data (todos los datos abiertos liberados ya sea a nivel gubernamental o no gubernamental).